

Laporan Teknis Komprehensif
Capstone Project
SpendWise (AI Smart Financial Behavior Analyzer)



(CDCC284D6Y2528) - (Iqbal Wahyufirmansyah) - (Data Scientist)
(CDCC006D6X2179) - (Azarine Nasya Aziza) - (Data Scientist)

ID Tim Capstone Project: CC26-PSU228
Coding Camp 2026 powered by DBS Foundation

Daftar Isi

Daftar Isi	1
Daftar Tabel	3
Daftar Gambar	4
Bab I Pendahuluan	5
1.1 Latar Belakang Masalah	5
1.2 Pertanyaan Bisnis	5
Bab II Tinjauan Pustaka	6
2.1 Literasi Keuangan dan Perilaku Finansial Generasi Muda	6
2.1.1 Konsep Literasi Keuangan	6
2.1.2 Ketahanan Finansial dan Kerentanan Keuangan	6
2.1.3 Klasifikasi Status Finansial Individu	6
2.2 <i>Data Wrangling</i>	7
2.2.1 Validasi dan Pembersihan Data	7
2.2.2 Deteksi dan Penanganan <i>Outlier</i> dengan Metode IQR	7
2.3 <i>Exploratory Data Analysis</i> (EDA)	7
2.4 <i>Feature Engineering</i>	8
2.5 <i>Data Splitting</i>	8
Bab III Pemrosesan dan Eksplorasi Data	9
3.1 <i>Data Wrangling</i>	9
3.1.1 <i>Gathering Data</i>	9
3.1.2 <i>Assessing Data</i>	11
3.1.3 <i>Data Cleaning</i>	12
3.2 <i>Exploratory Data Analysis</i>	12
3.3 <i>Feature Selection</i>	12
3.4 Standarisasi	12
3.5 <i>Feature Engineering</i>	13
3.6 <i>Splitting Data</i>	14
3.7 Penerapan ke Streamlit	15
Bab IV Hasil dan Pembahasan	17
4.1 Hasil <i>Data Wrangling</i>	17
4.2 Hasil <i>Exploratory Data Analysis</i>	19
4.3 Hasil Standarisasi	21
4.4 Hasil <i>Labelling Data</i>	22
4.5 Menjawab Pertanyaan Bisnis	22

4.5.1 Apa pola alokasi keuangan yang membedakan cluster rentan, <i>moderate</i> , dan sehat?.....	22
4.5.2 Fitur apa yang paling berpengaruh terhadap kesehatan finansial seseorang?	24
4.6 Visualisasi Streamlit.....	25
Bab V Penutup	28
5.1 Kesimpulan.....	28
5.2 Saran	28
Daftar Pustaka	29

Daftar Tabel

Tabel 3.1 Jenis Kolom dan Tipe Data pada Dataset yang Digunakan	9
Tabel 3.2 Fitur dan Target yang Digunakan untuk Pelatihan Model.....	14

Daftar Gambar

Gambar 4.1 Hasil Validasi Tipe Data	17
Gambar 4.2 Hasil Validasi <i>Missing Value</i>	18
Gambar 4.3 Hasil Validasi Duplikasi pada Data	18
Gambar 4.4 Hasil Validasi Inkonsistensi Data	18
Gambar 4.5 Hasil Validasi <i>Outlier</i>	19
Gambar 4.6 Hasil <i>Trimming Data</i>	19
Gambar 4.7 Hasil Analisis Korelasi Antar Variabel.....	20
Gambar 4.8 Hasil Transformasi Data	22
Gambar 4.9 Grafik Distribusi Klasifikasi Status Finansial Individu	22
Gambar 4.10 Perbandingan Alokasi Pendapatan Antar Kategori Finansial	23
Gambar 4.11 Hasil Analisis Korelasi Antar Variabel	24
Gambar 4.12 Halaman Ringkasan Status Finansial	25
Gambar 4.13 Visualisasi Jawaban Pertanyaan Bisnis 1	26
Gambar 4.14 Visualisasi Jawaban Pertanyaan Bisnis 2	27

Bab I

Pendahuluan

1.1 Latar Belakang Masalah

Literasi keuangan merupakan salah satu pondasi penting untuk mewujudkan kesejahteraan finansial setiap individu. Berdasarkan data Otoritas Jasa Keuangan (OJK) dalam Survei Nasional Literasi Keuangan Indonesia (SNLKI) tahun 2025, indeks literasi keuangan nasional Indonesia berada pada angka 66,46%. Meski trennya positif, angka ini belum mencerminkan kondisi ideal, khususnya untuk kelompok usia muda yang masih rentan terhadap perilaku keuangan yang tidak sehat. Kondisi ini tidak hanya terjadi di Indonesia, tetapi juga terjadi di 26 negara. Hal ini ditunjukkan dengan sebanyak hampir sepertiga responden (125.787 orang dewasa) hanya memiliki tabungan yang cukup untuk bertahan selama satu minggu dan hampir setengahnya mengkhawatirkan kemampuan mereka dalam memenuhi kebutuhan sehari-hari (Hamid *et al.*, 2023).

Generasi muda menghadapi tantangan yang unik dalam mengelola keuangan pribadi. Kemudahan akses terhadap teknologi digital justru berpotensi mendorong perilaku konsumtif apabila tidak diimbangi dengan literasi dan kendali keuangan yang memadai. Lusardi *et al.* (2020) menunjukkan bahwa literasi keuangan yang rendah berhubungan dengan kerentanan finansial, termasuk ketidakmampuan mengakumulasi tabungan darurat dan tingginya ketergantungan pada utang. Permasalahan ini diperparah oleh ketiadaan alat bantu personal yang mampu menganalisis perilaku keuangan individu secara spesifik. Saran keuangan yang ada saat ini bersifat umum dan tidak dipersonalisasi.

Menjawab tantangan tersebut, tim CC26-PSU228 melakukan inovasi SpendWise, yaitu pelacak keuangan personal berbasis *Artificial Intelligence* (AI). Sebagai bagian dari pengembangan sistem ini, peran *Data Scientist* mencakup pengolahan data mentah transaksi keuangan hingga menghasilkan dataset yang bersih dan representatif. Dataset ini selanjutnya dapat digunakan untuk permodelan oleh *AI Engineer* dan diterapkan oleh *Full Stack Web Developer*.

1.2 Pertanyaan Bisnis

Melalui proyek ini, pertanyaan yang ingin dijawab, yaitu:

1. Apa pola alokasi keuangan yang membedakan cluster rentan, *moderate*, dan sehat?
2. Fitur apa yang paling berpengaruh terhadap klasifikasi kesehatan finansial?

Bab II

Tinjauan Pustaka

2.1 Literasi Keuangan dan Perilaku Finansial Generasi Muda

2.1.1 Konsep Literasi Keuangan

Literasi keuangan adalah kemampuan individu dalam memahami dan menggunakan berbagai keterampilan keuangan, termasuk pengelolaan keuangan pribadi, penganggaran, dan investasi. OJK mengukur literasi keuangan melalui lima aspek utama, yaitu pengetahuan (*knowledge*), keterampilan (*skills*), kepercayaan (*beliefs*), sikap (*attitude*), dan perilaku (*behavior*) masyarakat terhadap produk dan layanan keuangan (OJK, 2025). Penelitian oleh Lusardi *et al.* (2020) menunjukkan bahwa individu dengan literasi keuangan lebih tinggi mampu mempersiapkan dana darurat, memiliki lebih sedikit utang, dan memiliki kecenderungan yang besar untuk menabung dan merencanakan masa pensiun.

2.1.2 Ketahanan Finansial dan Kerentanan Keuangan

Ketahanan finansial merujuk pada kemampuan individu dalam menghadapi guncangan keuangan dan memulihkan diri dari kesulitan finansial (Hamid *et al.*, 2023). Dalam penelitiannya, Hamid *et al.* (2023) mendefinisikan ketahanan finansial melalui lima komponen, yaitu menjaga kendali atas keuangan (*keeping control of money*), mengelola pengeluaran (*taking care of expenditures*), memiliki bantalan keuangan (*having a financial cushion*), menangani tekanan keuangan (*handling financial shortfall*), dan memiliki perencanaan keuangan (*having a financial planning*).

2.1.3 Klasifikasi Status Finansial Individu

Dalam pengerjaan proyek SpendWise, status finansial individu diklasifikasikan menjadi tiga kategori, yaitu kategori rentan, *moderate*, dan sehat berdasarkan nilai *Savings Ratio*. Pendekatan ini mengacu pada konsep *financial resilience* yang menempatkan kemampuan menabung sebagai salah satu indikator utama ketahanan finansial. Hamid *et al.* (2023) menggunakan rasio tabungan terhadap pendapatan untuk mengelompokkan individu ke dalam beberapa rentang *savings rate*, yaitu kurang dari 5%, 5-10%, 10-20%, 20-35%, 35-50%, dan lebih dari 50%. Penelitian tersebut menunjukkan bahwa individu dengan proporsi tabungan yang lebih tinggi cenderung memiliki tingkat ketahanan finansial yang lebih baik karena memiliki kemampuan yang lebih besar untuk menghadapi guncangan ekonomi tanpa bergantung pada pinjaman.

2.2 Data Wrangling

2.2.1 Validasi dan Pembersihan Data

Data wrangling merupakan proses fundamental dalam analisis data yang mencakup identifikasi dan penanganan data yang tidak valid, tidak lengkap, atau tidak konsisten. Menurut Wickham (2014), data bersih adalah data yang terstruktur sehingga setiap variabel berada dalam kolom tersendiri, setiap observasi berada dalam baris tersendiri, dan setiap nilai berada dalam sel tersendiri. Validasi data dalam proyek ini mencakup aspek validasi tipe data, pengecekan *missing value*, pengecekan duplikasi, dan validasi konsistensi logis antar kolom.

2.2.2 Deteksi dan Penanganan *Outlier* dengan Metode IQR

Metode IQR atau *Interquartile Range* merupakan salah satu teknik yang paling banyak digunakan dalam deteksi *outlier* data numerik. IQR didefinisikan sebagai selisih antara kuartil ketiga (Q3) dan kuartil pertama (Q1). Suatu nilai dinyatakan sebagai *outlier* apabila berada di luar rentang $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$ (Tukey, 1977). Dalam proyek ini, metode IQR diterapkan pada seluruh kolom finansial numerik utama, seperti *income* dan berbagai kategori pengeluaran. Sementara itu, kolom demografis, seperti *age* dan *dependents*, dikecualikan karena nilai ekstrem pada kolom tersebut dapat dianggap valid secara kontekstual. Strategi penanganan yang dipilih adalah penghapusan baris karena jumlah *outlier* yang teridentifikasi relatif kecil sehingga tidak berdampak signifikan pada representativitas data.

2.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) adalah pendekatan analitik yang bertujuan untuk meringkas karakteristik utama suatu dataset, seringkali menggunakan metode visual. Tukey (1977) memperkenalkan EDA sebagai langkah kritis sebelum pemodelan formal guna memahami distribusi data, mengidentifikasi anomali, dan menemukan pola yang dapat mengarahkan pemilihan model yang tepat. Dalam proses EDA, analisis yang dilakukan adalah analisis korelasi dan distribusi kelas.

Analisis korelasi mengukur kekuatan dan arah hubungan linear antara dua variabel numerik. Koefisien korelasi Pearson (r) memiliki rentang nilai -1 hingga +1 dengan nilai yang mendekati 1 menunjukkan korelasi kuat (Mukaka, 2012). Dalam proyek ini, *correlation heatmap* digunakan untuk mengidentifikasi variabel yang paling berpengaruh terhadap *financial status*. Hamid *et al.* (2023) menunjukkan bahwa beban cicilan dan sewa berkaitan negatif dengan ketahanan

finansial. Di sisi lain, analisis distribusi kelas dilakukan untuk mengetahui penyebaran kelas dalam dataset yang dimiliki. Ketidakseimbangan kelas dapat menyebabkan model yang dihasilkan bias terhadap kelas mayoritas.

2.4 Feature Engineering

Feature engineering adalah proses transformasi data mentah menjadi fitur yang lebih representatif bagi model. Salah satu teknik yang digunakan adalah teknik standarisasi data keuangan multi-mata uang, seperti normalisasi berbasis rasio. Pendekatan ini menghasilkan fitur yang bersifat *scale-invariant* sehingga model tidak terpengaruh oleh perbedaan skala nominal antar pengguna dari latar belakang ekonomi yang berbeda (Greinger *et al.*, 1996; Han *et al.*, 2012).

Setelah melakukan standarisasi data, dilakukan pembuatan label target yang memanfaatkan pengetahuan domain untuk mendefinisikan kelas secara eksplisit melalui aturan logis. Pendekatan ini umumnya digunakan dalam skenario, di mana label *ground truth* tidak tersedia dalam dataset mentah, tetapi kriteria klasifikasi dapat diturunkan dari teori atau standar yang sudah diakui (Ratner *et al.*, 2020). Penggunaan *savings ratio* sebagai basis klasifikasi sangat sesuai. Hal ini didukung oleh literatur, yaitu kecukupan tabungan secara mandiri adalah indikator ketahanan finansial yang baik (Kempson *et al.*, 2017; McKnight & Rucci, 2020).

2.5 Data Splitting

Pembagian data menjadi set pelatihan dan set pengujian merupakan standar dalam *machine learning* untuk mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Rasio 80:20 digunakan pada proyek ini dengan *random_state* = 42 untuk memastikan reproduktibilitas hasil (Hastie *et al.*, 2009; James *et al.*, 2021).

Bab III

Pemrosesan dan Eksplorasi Data

3.1 Data Wrangling

3.1.1 Gathering Data

Pada tahapan ini, pengumpulan data dilakukan melalui platform Kaggle yang menyediakan berbagai dataset finansial untuk analisis lebih lanjut. Dataset yang dipilih memiliki volume sekitar 20.000 baris dan 27 kolom. Detail mengenai setiap kolom dalam dataset ini disajikan pada **Tabel 3.1**. Sebelumnya, pengujian sempat dilakukan menggunakan dataset yang berbeda. Namun, karena ditemukan banyak inkonsistensi data yang signifikan, diputuskan untuk mengganti data tersebut dengan dataset yang digunakan saat ini.

Tabel 3.1 Jenis Kolom dan Tipe Data pada Dataset yang Digunakan

No	Nama Kolom	Tipe Data	Keterangan
1	<i>Income</i>	float64	Jumlah pendapatan bulanan individu dalam satuan mata uang.
2	<i>Age</i>	int64	Usia dari individu.
3	<i>Dependents</i>	int64	Jumlah tanggungan yang ditanggung oleh individu.
4	<i>Occupation</i>	object	Jenis pekerjaan atau peran jabatan dari individu.
5	<i>City_Tier</i>	object	Skala wilayah tempat tinggal individu (misalnya Tier 1, Tier 2, dll).
6	<i>Rent</i>	float64	Pengeluaran bulanan untuk sewa tempat tinggal.
7	<i>Loan_Repayment</i>	float64	Pengeluaran bulanan untuk pembayaran cicilan atau pinjaman.
8	<i>Insurance</i>	float64	Pengeluaran bulanan untuk premi asuransi.
9	<i>Groceries</i>	float64	Pengeluaran bulanan untuk belanja bahan makanan.

No	Nama Kolom	Tipe Data	Keterangan
10	<i>Transport</i>	float64	Pengeluaran bulanan untuk biaya transportasi.
11	<i>Eating_Out</i>	float64	Pengeluaran bulanan untuk biaya makan di luar.
12	<i>Entertainment</i>	float64	Pengeluaran bulanan untuk biaya hiburan.
13	<i>Utilities</i>	float64	Pengeluaran bulanan untuk tagihan rutin (seperti air dan listrik).
14	<i>Healthcare</i>	float64	Pengeluaran bulanan untuk biaya kesehatan.
15	<i>Education</i>	float64	Pengeluaran bulanan untuk biaya pendidikan.
16	<i>Miscellaneous</i>	float64	pengeluaran lainnya.
17	<i>Desired_Savings_Percentage</i>	float64	Target persentase tabungan bulanan yang ingin dicapai dari total pendapatan.
18	<i>Desired_Savings</i>	float64	Nominal target tabungan bulanan dalam bentuk nilai mata uang.
19	<i>Disposable_Income</i>	float64	Sisa pendapatan individu setelah dikurangi oleh seluruh pengeluaran bulanan.
20	<i>Potential_Savings_Groceries</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran bahan makanan.
21	<i>Potential_Savings_Transport</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran transportasi.
22	<i>Potential_Savings_Eating_Out</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran makan di luar.

No	Nama Kolom	Tipe Data	Keterangan
23	<i>Potential_Savings_Entertainment</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran hiburan.
24	<i>Potential_Savings_Utilities</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran tagihan utilitas.
25	<i>Potential_Savings_Healthcare</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran kesehatan.
26	<i>Potential_Savings_Education</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran pendidikan.
27	<i>Potential_Savings_Miscellaneous</i>	float64	Estimasi jumlah uang yang masih dapat dihemat dari pengeluaran rupa-rupa lainnya.

3.1.2 Assessing Data

Setelah proses pengumpulan data selesai, tahapan berikutnya adalah *assessing data* untuk memeriksa kualitas data sebelum dilakukan pembersihan. Penilaian pertama dilakukan dengan memeriksa apakah terdapat tipe data yang tidak sesuai, dan setelah dilakukan pengecekan keberadaan *missing values*, dan hasilnya menunjukkan tidak ada nilai yang hilang pada dataset ini. Selanjutnya, pemeriksaan data duplikat dilakukan, yang mengonfirmasi bahwa tidak ada baris data yang ganda.

Pemeriksaan inkonsistensi logis juga diterapkan menggunakan fungsi kustom untuk memastikan validitas hubungan antarvariabel sebuah langkah preventif yang didasarkan pada evaluasi kegagalan dataset sebelumnya. Hasil pemeriksaan menunjukkan data telah konsisten secara logis.

Terakhir, deteksi *outlier* dilakukan secara selektif. Pengecekan ini hanya difokuskan pada fitur-fitur numerik yang merepresentasikan komponen pengeluaran yang akan digunakan dalam pembangunan model. Sementara itu, kolom yang tidak relevan dengan pola pengeluaran tidak diikutsertakan dalam pembersihan *outlier*. Langkah ini diambil sebagai strategi untuk meminimalkan

risiko kehilangan informasi penting secara berlebihan yang dapat mengurangi volume dataset.

3.1.3 Data Cleaning

Berdasarkan hasil penilaian data, tahap *data cleaning* difokuskan pada penanganan *outlier*. Metode pembersihan yang diterapkan adalah penghapusan seluruh data yang teridentifikasi sebagai *outlier (trimming)*. Langkah ini dipilih karena variabel-variabel dalam dataset ini memiliki dependensi yang kuat satu sama lain. Jika dilakukan metode pembatasan nilai, seperti *capping*, dikhawatirkan akan memicu inkonsistensi logis antar-fitur. Oleh karena itu, penghapusan data *outlier* dinilai sebagai solusi terbaik untuk menjaga validitas data.

3.2 Exploratory Data Analysis

Exploratory Data Analysis (EDA) dilakukan untuk mengidentifikasi karakteristik, tren, dan pola tersembunyi di dalam dataset. Dalam penelitian ini, analisis korelasi Pearson (*Pearson Correlation*) digunakan sebagai metode utama untuk mengukur kekuatan dan arah hubungan linier antarvariabel numerik yang tersedia.

3.3 Feature Selection

Seleksi fitur (*feature selection*) dilakukan untuk menyaring dan mempertahankan variabel yang relevan bagi pengembangan model. Pada tahap ini, fitur yang dipertahankan dispesifikasikan pada variabel yang berkaitan langsung dengan pengeluaran. Fitur seperti *Age*, *Occupation*, *City_Tier*, dan *Dependents* dihapus karena tidak menunjukkan korelasi yang signifikan dalam analisis awal. Selain itu, ditemukan beberapa anomali data, seperti baris yang mencatat individu berusia 64 tahun dengan status pekerjaan sebagai *student* namun memiliki 4 *dependents*. Kondisi yang tidak realistis ini berpotensi bias, sehingga fitur-fitur tersebut dieksklusi dari penelitian. Lebih lanjut, fitur *Desired_Savings_Percentage*, *Desired_Savings*, serta seluruh variabel *Potential_Savings* juga dihapus karena penelitian ini berfokus sepenuhnya pada pola pengeluaran riil pengguna.

3.4 Standarisasi

Proses standarisasi dilakukan karena dataset asli menggunakan satuan mata uang Rupee. Untuk mengeliminasi bias skala dan perbedaan nilai mata uang, data ditransformasikan menjadi bentuk rasio terhadap *income*. Standarisasi dilakukan

dengan membagi setiap nilai pada kolom kategori pengeluaran dan *disposal income* dengan total *income* individu yang bersangkutan, menggunakan persamaan berikut:

$$Rasio = \frac{\text{Nilai Fitur Pengeluaran}}{\text{Total Income}}$$

Melalui transformasi ini, data yang semula bertipe nominal mata uang berubah menjadi data rasio.

3.5 Feature Engineering

Sebelum menetapkan metode pelabelan berbasis *rule-based*, telah dilakukan pengujian menggunakan pendekatan lain, yaitu *clustering* dan pembobotan berbasis indikator finansial. Namun, pelabelan melalui *clustering* menghasilkan nilai akurasi model klasifikasi lanjutan yang terlalu tinggi hingga mencapai 0,99. Angka yang terlalu sempurna ini mengindikasikan adanya gejala *overfitting* sehingga metode tersebut tidak digunakan.

Di sisi lain, ketika mengevaluasi metode pembobotan menggunakan *heatmap correlation*, ditemukan nilai korelasi yang sangat tinggi antar-beberapa indikator indikatif. Kondisi ini mengindikasikan adanya multikolinearitas sehingga pembobotan menjadi tidak objektif dan berpotensi mengganggu performa generalisasi model kedepannya.

Oleh karena itu, dilakukan rekayasa label menggunakan pendekatan *domain knowledge* melalui aturan logis secara eksplisit. Pendekatan ini umum digunakan pada skenario saat label *ground truth*, tetapi kriteria klasifikasi dapat diturunkan dari teori atau standar industri yang diakui (Ratner *et al.*, 2020). Penentuan target klasifikasi ini menggunakan variabel *Savings_Ratio* sebagai basisnya, mengingat kecukupan tabungan merupakan indikator ketahanan finansial yang valid (McKnight & Rucci, 2020). Batas ambang (*threshold*) sebesar 10% dan 20% diadopsi melalui penyederhanaan penelitian Hamid *et al.* (2023) yang mengelompokkan yang menggunakan rasio tabungan terhadap pendapatan untuk mengelompokkan individu ke dalam beberapa rentang *Savings_Ratio*, yaitu kurang dari 5%, 5-10%, 10-20%, 20-35%, 35-50%, dan lebih dari 50%. Kemudian agar label yang dihasilkan tidak terlalu banyak maka disederhanakan menjadi 3 kategori, yaitu

1. **Rentan:** jika *Savings_Ratio* di bawah 10%.
2. **Moderate:** jika *Savings_Ratio* bernilai 10% hingga 20%.
3. **Sehat:** jika *Savings_Ratio* di atas 20%.

3.6 Splitting Data

Sebelum dilakukan pembagian data *data splitting*, kolom *Savings_Ratio* dihapus terlebih dahulu untuk mencegah terjadinya *data leakage* karena fitur tersebut merupakan dasar dari pembentukan label target. Selanjutnya, data dibagi menjadi *training set* dan *testing set* menggunakan rasio 80:20. Proses pemisahan ini menerapkan metode stratifikasi (*stratify=y*) untuk mempertahankan konsistensi distribusi kelas target pada data latih maupun data uji. Fitur dan target yang akan digunakan untuk melatih model dapat dilihat pada **Tabel 3.2**.

Tabel 3.2 Fitur dan Target yang Digunakan untuk Pelatihan Model

Nama Kolom	Type Data	Deskripsi	Status
<i>Rent_Ratio</i>	Float	Persentase dari total pendapatan yang dihabiskan untuk biaya sewa tempat tinggal.	Feature
<i>Loan_Repayment_Ratio</i>	Float	Persentase dari total pendapatan yang digunakan untuk membayar cicilan atau pinjaman (utang).	Feature
<i>Insurance_Ratio</i>	Float	Persentase dari total pendapatan yang dialokasikan untuk membayar premi asuransi.	Feature
<i>Groceries_Ratio</i>	Float	Persentase dari total pendapatan yang digunakan untuk belanja bahan makanan atau kebutuhan pokok.	Feature
<i>Transport_Ratio</i>	Float	Persentase dari total pendapatan yang dihabiskan untuk biaya transportasi.	Feature
<i>Eating_Out_Ratio</i>	Float	Persentase dari total pendapatan yang dihabiskan untuk biaya makan di luar (konsumtif).	Feature
<i>Entertainment_Ratio</i>	Float	Persentase dari total pendapatan yang dialokasikan untuk kebutuhan hiburan.	Feature

Nama Kolom	Tipe Data	Deskripsi	Status
<i>Utilities_Ratio</i>	Float	Persentase dari total pendapatan yang digunakan untuk membayar tagihan utilitas (listrik, air, internet, dll).	Feature
<i>Healthcare_Ratio</i>	Float	Persentase dari total pendapatan yang disisihkan atau digunakan untuk biaya kesehatan.	Feature
<i>Education_Ratio</i>	Float	Persentase dari total pendapatan yang dialokasikan untuk biaya pendidikan.	Feature
<i>Miscellaneous_Ratio</i>	Float	Persentase dari total pendapatan yang digunakan untuk pengeluaran rupa-rupa atau pengeluaran lainnya yang tidak terklasifikasi.	Feature
<i>Financial_Status</i>	Integer	Label atau kelas yang merepresentasikan tingkat kesehatan finansial pengguna (0 = Rentan, 1 = Moderate, 2 = Sehat).	Target

3.7 Penerapan ke Streamlit

Data yang diintegrasikan ke dalam platform Streamlit merupakan dataset yang telah melalui proses pembersihan, tetapi belum melalui *data splitting*. Penggunaan framework Streamlit bertujuan untuk membangun *dashboard* interaktif sehingga visualisasi data menjadi lebih informatif, dinamis, dan dapat diakses oleh publik secara luas melalui tautan internet setelah di-*deploy* ke Streamlit Cloud. Dashboard ini dirancang memiliki dua halaman utama yang dapat diakses pengguna melalui *sidebar*:

- 1. Halaman Pertama (Ringkasan Data):** Halaman ini menyajikan ringkasan eksekutif dari seluruh variabel berdasarkan kelompok kategorinya. Pada bagian atas halaman, ditampilkan *Key Performance Indicators* (KPI) utama yang meliputi total responden, rata-rata rasio tabungan, rata-rata biaya sewa, dan identifikasi alokasi pendapatan tertinggi. Selanjutnya, diagram *pie chart* dan diagram *radar chart* digunakan untuk memvisualisasikan sebaran kategori

kesehatan finansial pengguna. Halaman ini ditutup dengan komponen *progress bar* untuk menunjukkan persentase alokasi pendapatan pada setiap kategori pengeluaran.

2. **Halaman Kedua (Analisis Pertanyaan Bisnis):** Halaman ini difokuskan untuk menyajikan jawaban terstruktur atas pertanyaan bisnis yang telah dirumuskan sebelumnya. Setiap pertanyaan bisnis dilengkapi dengan visualisasi data interaktif yang relevan guna memberikan wawasan yang mendalam dan mudah dipahami oleh pengguna.

Bab IV

Hasil dan Pembahasan

4.1 Hasil *Data Wrangling*

Hasil proses *data wrangling* berupa pengecekan tipe data Selanjutnya dilakukan validasi *tipe data*, *missing value*, duplikasi inkonsistensi data, dan *outlier* sehingga dilakukan *data cleaning*. Untuk output dari validasi tipe data dapat dilihat pada **Gambar 4.1**. Dapat dilihat bahwa format data sudah sesuai sehingga tidak diperlukan handling tipe data seperti merubah format tipe data.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 27 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Income                                20000 non-null  float64
1   Age                                   20000 non-null  int64
2   Dependents                           20000 non-null  int64
3   Occupation                           20000 non-null  object
4   City_Tier                            20000 non-null  object
5   Rent                                  20000 non-null  float64
6   Loan_Repayment                       20000 non-null  float64
7   Insurance                            20000 non-null  float64
8   Groceries                            20000 non-null  float64
9   Transport                            20000 non-null  float64
10  Eating_Out                           20000 non-null  float64
11  Entertainment                         20000 non-null  float64
12  Utilities                            20000 non-null  float64
13  Healthcare                           20000 non-null  float64
14  Education                            20000 non-null  float64
15  Miscellaneous                         20000 non-null  float64
16  Desired_Savings_Percentage            20000 non-null  float64
17  Desired_Savings                       20000 non-null  float64
18  Disposable_Income                    20000 non-null  float64
19  Potential_Savings_Groceries           20000 non-null  float64
20  Potential_Savings_Transport           20000 non-null  float64
21  Potential_Savings_Eating_Out          20000 non-null  float64
22  Potential_Savings_Entertainment       20000 non-null  float64
23  Potential_Savings_Uutilities          20000 non-null  float64
24  Potential_Savings_Healthcare          20000 non-null  float64
25  Potential_Savings_Education           20000 non-null  float64
26  Potential_Savings_Miscellaneous        20000 non-null  float64
dtypes: float64(23), int64(2), object(2)
memory usage: 4.1+ MB
```

Gambar 4.1 Hasil Validasi Tipe Data

Selanjutnya dilakukan validasi *missing value* untuk *output* dari validasi *missing value* dapat dilihat pada **Gambar 4.2**, di mana tidak ditemukan adanya *missing value* pada seluruh kolom yang ada. Hal ini menunjukkan bahwa tidak diperlukan metode *handling missing value*, seperti menghapus nilai *null* atau menggantinya dengan nilai lain.

	0	Healthcare	0
Income	0	Education	0
Age	0	Miscellaneous	0
Dependents	0	Desired_Savings_Percentage	0
Occupation	0	Desired_Savings	0
City_Tier	0	Disposable_Income	0
Rent	0	Potential_Savings_Groceries	0
Loan_Repayment	0	Potential_Savings_Transport	0
Insurance	0	Potential_Savings_Eating_Out	0
Groceries	0	Potential_Savings_Entertainment	0
Transport	0	Potential_Savings_Uilities	0
Eating_Out	0	Potential_Savings_Healthcare	0
Entertainment	0	Potential_Savings_Education	0
Utilities	0	Potential_Savings_Miscellaneous	0

Gambar 4.2 Hasil Validasi *Missing Value*

Selanjutnya, dilakukan pengecekan duplikasi pada data. Hasil dari validasi duplikasi data duplikat dapat dilihat pada **Gambar 4.3**. Pada gambar tersebut, terlihat tidak ada duplikasi pada dataset sehingga tidak diperlukan metode *drop* baris duplikat.

```
np.int64(0)
```

Gambar 4.3 Hasil Validasi Duplikasi pada Data


Setelah dilakukan pengecekan duplikasi pada data, dataset kemudian divalidasi inkonsistensi datanya. Hasil dari validasi inkonsisten data dapat terlihat pada **Gambar 4.4**. Melalui gambar tersebut, terlihat tidak ada inkonsistensi yang terdeteksi sehingga data dapat disimpulkan valid.

```
Jumlah baris dengan Disposable Income salah: 0
Jumlah baris dengan Desired Savings salah: 0
```

Gambar 4.4 Hasil Validasi Inkonsistensi Data

Selanjutnya, dilakukan proses validasi *outlier*. Hasil validasi dapat dilihat pada **Gambar 4.5**. Pada gambar tersebut, terlihat bahwa banyak fitur yang mengalami *outlier*. *Outlier* pada dataset ini didominasi dengan nilai yang berada di atas IQR 3 atau batas atasnya. Oleh karena itu, dilakukan *handling* dengan melakukan

trimming data sehingga data *outlier* hilang dan konsistensi antar data pengeluaran akan tetap terjaga.



Gambar 4.5 Hasil Validasi *Outlier*

Tahap terakhir pada *data wrangling* adalah tahap *data cleaning*. Berdasarkan pada **Gambar 4.6**, terdapat 20.000 baris data awal. Kemudian, setelah melakukan pengecekan berbagai parameter, terdapat dataset yang tidak sesuai sehingga dilakukan *trimming data*. Proses ini menghapus 3.568 baris sehingga menyisakan 16.432 baris saja.


Data awal: 20000 baris
Data bersih: 16432 baris
Data dibuang: 3568 baris

Gambar 4.6 Hasil *Trimming Data*

4.2 Hasil *Exploratory Data Analysis*

Pada proses *Exploratory Data Analysis* (EDA), dilakukan analisis korelasi menggunakan Pearson (r). Melalui analisis ini, arah dan kekuatan hubungan masing-masing variabel. Arah hubungan ditunjukkan oleh nilai positif (+) dan negatif (-), di mana nilai positif menunjukkan bahwa kedua variabel bergerak

searah sehingga nilainya sebanding dan nilai negatif menunjukkan bahwa kedua variabel bergerak berlawanan arah sehingga nilainya berbanding terbalik. Sementara itu, kekuatan hubungan dapat dilihat melalui nilai 0 hingga 1, di mana nilai hubungan dua variabel yang semakin mendekati 1 menunjukkan adanya korelasi yang kuat antar variabel.



Gambar 4.7 Hasil Analisis Korelasi Antar Variabel

Berdasarkan visualisasi matriks korelasi (*heatmap correlation*) yang disajikan pada **Gambar 4.7**, dapat ditarik beberapa kesimpulan utama terkait hubungan antar variabel, yaitu:

1. *Income* sebagai penggerak utama pengeluaran dan tabungan

Variabel *Income* memiliki korelasi positif yang sangat kuat dengan hampir semua kategori pengeluaran maupun tabungan, dengan koefisien korelasi berkisar antara 0,78 hingga 0,98 (direpresentasikan oleh gradasi warna merah tua pada *heatmap*). Hubungan linear yang sangat kuat ini terlihat pada variabel *Rent* (0,94), *Groceries* (0,94), *Transport* (0,98), dan *Healthcare* (0,98), serta variabel finansial seperti *Desired_Savings* (0,94) dan *Disposable_Income* (0,88).

2. Tidak ada hubungan linear pada faktor *age* dan *dependents*

Variabel *age* dan *dependents* menunjukkan koefisien korelasi yang sangat mendekati nol di seluruh baris dan kolom, yaitu berada pada rentang -0,02 hingga 0,02 (direpresentasikan oleh warna biru/netral). Hal ini mengindikasikan bahwa dalam dataset ini, faktor usia maupun banyaknya jumlah tanggungan tidak memengaruhi secara linear besaran pendapatan seseorang, pola alokasi pengeluaran, ataupun jumlah uang yang mereka tabung setiap bulannya.

3. Korelasi negatif pada *Loan_Repayment*

Variabel *Loan_Repayment* menunjukkan korelasi negatif yang moderat dengan tingkat *Income* sebesar -0,45. Korelasi negatif ini mengindikasikan sebuah pola di mana kelompok responden dengan tingkat pendapatan yang lebih tinggi cenderung memiliki beban atau nilai pelunasan pinjaman yang lebih rendah, atau sebaliknya. Selain itu, hubungan antara *Loan_Repayment* dengan variabel pengeluaran lainnya juga terpantau lemah atau bernilai negatif.

4. Konsistensi tren gaya hidup antar-kategori pengeluaran

Berbagai kategori pengeluaran variabel, seperti *Groceries*, *Transport*, *Eating_Out*, *Entertainment*, dan *Utilities*, memiliki korelasi yang sangat tinggi satu sama lain, dengan mayoritas nilai koefisien di atas 0,90. Hubungan searah yang kuat ini menunjukkan adanya tren gaya hidup yang selaras di antara para responden. Seseorang yang mengalokasikan dana tinggi pada satu sektor (misalnya transportasi) cenderung akan membelanjakan dana yang tinggi pula pada sektor hiburan atau makanan di luar, yang mana seluruh konsistensi pengeluaran ini didorong secara simultan oleh tingginya daya beli dari faktor *Income*.

4.3 Hasil Standarisasi


Proses standarisasi dilakukan dengan membagi nilai setiap komponen pengeluaran terhadap total pemasukan (*income*). Hasil transformasi data diperoleh sebagaimana ditunjukkan pada **Gambar 4.8**. Pada gambar tersebut, dapat dilihat bahwa setiap fitur pengeluaran telah berhasil dikonversi menjadi bentuk rasio terhadap *income*. Transformasi ini mengeliminasi ketergantungan data pada satuan mata uang asli, yaitu Rupee (INR), sehingga dataset kini bersifat bebas skala dan dapat diadaptasikan secara universal untuk analisis pada mata uang lain tanpa kehilangan esensi proporsi pengeluarannya.

	Rent_Ratio	Loan_Repayment_Ratio	Insurance_Ratio	Groceries_Ratio	Transport_Ratio	Eating_Out_Ratio	Entertainment_Ratio	Utilities_Ratio	Healthcare_Ratio	Education_Ratio	Miscellaneous_Ratio	Savings_Ratio
0	0.299993	0.000000	0.049430	0.149172	0.059074	0.037004	0.034414	0.065231	0.034654	0.000000	0.018628	0.252376
1	0.199993	0.000000	0.032373	0.104932	0.057448	0.024177	0.039101	0.060542	0.042344	0.057772	0.021007	0.360274
2	0.149997	0.091567	0.043714	0.125340	0.063956	0.030055	0.034214	0.066876	0.043251	0.062738	0.012475	0.275796
3	0.199992	0.125124	0.025563	0.121977	0.051300	0.027851	0.026539	0.043825	0.046996	0.058096	0.020723	0.251874
4	0.199992	0.000000	0.041735	0.130648	0.070756	0.042171	0.030190	0.041176	0.041095	0.080552	0.018169	0.305478

Gambar 4.8 Hasil Transformasi Data

4.4 Hasil Labelling Data

Proses *labelling data* dilakukan dengan membuat label klasifikasi dataset berdasarkan *Savings_Ratio*. Melalui tahap ini, terdapat tiga label yang akan digunakan, yaitu label Rentan untuk individu dengan *Savings_Ratio* di bawah 0.1, *Moderate* untuk individu dengan *Savings_Ratio* antara 0.1-0.2, dan Aman untuk individu dengan *Savings_Ratio* di atas 0.2. Setelah dilakukan labelling data, ditemukan adanya *data imbalance* yang dapat dilihat pada **Gambar 4.9**. Kategori Sehat mendominasi persebaran distribusi diikuti oleh moderate lalu disusul oleh Rentan. Melihat persebaran secara keseluruhan, angka ini mencerminkan kondisi kesehatan finansial yang sangat positif dalam dataset, di mana mayoritas individu berada di zona aman dan proporsi kelompok yang rentan tergolong sangat minim.




Gambar 4.9 Grafik Distribusi Klasifikasi Status Finansial Individu

4.5 Menjawab Pertanyaan Bisnis

4.5.1 Apa pola alokasi keuangan yang membedakan cluster rentan, moderate, dan sehat?

Untuk menjawab pertanyaan ini, dilakukan visualisasi data menggunakan diagram batang, seperti pada **Gambar 4.10**. Berdasarkan gambar tersebut, terdapat perbedaan pola alokasi pendapatan yang sangat kontras di antara ketiga kategori finansial, terutama pada aspek beban biaya tetap (*fixed costs*) dan kemampuan menabung. Perbedaan alokasi ini dapat dijelaskan sebagai berikut:




Gambar 4.10 Perbandingan Alokasi Pendapatan Antar Kategori Finansial

1. **Kategori Rentan:** Individu pada kategori ini memiliki kapasitas menabung yang sangat kritis, di mana mereka hanya mampu menyisihkan rata-rata 5.5% dari pendapatan. Hal ini merupakan dampak langsung dari fixed-cost trap, yaitu tingginya beban biaya tetap untuk sewa tempat tinggal (rata-rata 29%) dan cicilan (rata-rata 15%). Akibatnya, kelompok ini memiliki ruang finansial yang sangat sempit dan rentan jika menghadapi pengeluaran darurat.
2. **Kategori Moderate:** Individu pada kategori ini menunjukkan kondisi finansial yang relatif lebih aman dengan rata-rata *savings rate* sebesar 16%. Kelompok ini sudah mampu mengamankan batas minimum investasi masa depan sekaligus memenuhi kebutuhan rutin, meskipun ruang gerak mereka masih sedikit tertahan oleh sisa beban cicilan (rata-rata 9.5%) dan sewa tempat tinggal (rata-rata 25%).
3. **Kategori Sehat:** Individu pada kategori ini menunjukkan tingkat kesehatan finansial yang paling ideal dengan kemampuan menyisihkan rata-rata 30.5% pendapatan untuk tabungan atau investasi. Kunci utama dari kesehatan finansial kelompok ini adalah keberhasilan mereka dalam menekan beban cicilan hingga titik minimal (rata-rata 2%) dan rasio sewa yang lebih rendah (rata-rata 20.5%) sehingga memberikan fleksibilitas arus kas yang sangat longgar.

Menariknya, rasio pengeluaran untuk kategori lainnya cenderung hampir serupa di antara ketiga kelompok tersebut. Hal ini menandakan bahwa faktor pembeda utama sekaligus beban finansial terberat yang memengaruhi kesehatan keuangan setiap kategori adalah biaya sewa tempat tinggal serta beban cicilan.

4.5.2 Fitur apa yang paling berpengaruh terhadap kesehatan finansial seseorang?

Untuk menjawab pertanyaan ini, dilakukan visualisasi data menggunakan *heatmap correlation* dengan model Pearson. Melalui analisis ini, dapat diketahui arah dan kekuatan hubungan antar variabel. Hal ini dapat mempermudah proses pengambilan kesimpulan dari dataset. Hasil analisis dapat dilihat pada **Gambar 4.11**.




Gambar 4.11 Hasil Analisis Korelasi Antar Variabel

Dari **Gambar 4.11**, dapat dilihat bahwa fitur *Savings_Ratio* sengaja dikecualikan dari analisis korelasi ini karena variabel tersebut digunakan secara langsung untuk membangun target *Financial_Status* sehingga berpotensi menyebabkan redudansi data. Jika ditinjau dari *heatmap* di atas, terlihat bahwa seluruh kategori pengeluaran memiliki korelasi negatif terhadap status finansial seseorang. Di antara seluruh variabel tersebut, *Loan_Repayment_Ratio* (-0.63) dan *Rent_Ratio* (-0.44) menunjukkan nilai korelasi negatif tertinggi. Hasil ini memvalidasi analisis pola alokasi keuangan sebelumnya, yang membuktikan secara empiris bahwa tingginya beban cicilan dan biaya sewa tempat tinggal merupakan faktor penentu utama yang menekan tingkat kesehatan finansial individu ke kategori Moderate maupun Rentan.

4.6 Visualisasi Streamlit


Hasil dari visualisasi Streamlit dapat dilihat pada **Gambar 4.12** yang merupakan halaman ringkasan status finansial. Pada halaman ini, pengguna dapat menerapkan filter per kategori untuk melihat bagaimana komposisi alokasi terhadap pendapatan untuk tiap kategori dan dapat melihat alokasi pendapatan untuk apa yang tertinggi untuk setiap kategorinya. Selanjutnya, pengguna juga bisa melihat bagaimana distribusi setiap kategori yang ada di dataset. Selain itu, terdapat visualisasi *radar chart* yang dapat memberikan insight mengenai perbedaan alokasi tiap-tiap kategori.



Gambar 4.12 Halaman Ringkasan Status Finansial


Sementara itu, pada halaman kedua, pengguna dapat melihat pertanyaan bisnis beserta wawasan yang diberikan. Pada **Gambar 4.13**, terlihat visualisasi data untuk pertanyaan bisnis pertama, yaitu "Apa pola alokasi keuangan yang membedakan cluster rentan, *moderate*, dan sehat?" Melalui visualisasi yang diberikan, dapat disimpulkan bahwa semakin rendah beban cicilan dan biaya

sewa yang ditanggung, semakin sehat kondisi finansial seseorang karena memberikan kelonggaran arus kas untuk menabung dan berinvestasi.



Gambar 4.13 Visualisasi Jawaban Pertanyaan Bisnis 1

Selanjutnya, masih pada halaman kedua, pengguna dapat melihat jawaban dari pertanyaan bisnis kedua, seperti terlihat pada **Gambar 4.14**. Pada halaman ini, terlihat visualisasi data untuk pertanyaan bisnis kedua, yaitu “Fitur apa yang paling berpengaruh terhadap kesehatan finansial seseorang?” Melalui visualisasi yang diberikan, dapat disimpulkan bahwa semakin tinggi beban cicilan dan sewa tempat tinggal, semakin rendah tingkat kesehatan finansial seseorang.



Gambar 4.14 Visualisasi Jawaban Pertanyaan Bisnis 2

Bab V

Penutup

5.1 Kesimpulan

Berdasarkan analisis data dan hasil visualisasi yang telah dilakukan untuk menjawab pertanyaan bisnis pada proyek SpendWise, didapatkan simpulan, yaitu:

1. Perbedaan pola alokasi pendapatan di antara ketiga cluster finansial sangat dipengaruhi oleh beban biaya tetap (*fixed costs*) dan kapasitas menabung, sementara rasio pengeluaran lainnya cenderung serupa. Semakin rendah beban cicilan dan biaya sewa tempat tinggal yang ditanggung, semakin sehat kondisi finansial seseorang karena memberikan kelonggaran arus kas untuk menabung dan berinvestasi.
2. Melalui analisis korelasi Pearson, terlihat bahwa seluruh kategori pengeluaran memiliki arah korelasi negatif terhadap status finansial individu. Fitur yang paling berpengaruh secara signifikan adalah *Loan_Repayment_Ratio* (beban cicilan), diikuti dengan *Rent_Ratio* (biaya sewa). Tingginya kedua rasio ini menjadi faktor penentu utama yang menekan tingkat kesehatan keuangan individu ke bawah kategori Sehat.

5.2 Saran

Berikut beberapa saran yang dapat digunakan untuk pengembangan selanjutnya:

1. Diharapkan pada pengembangan selanjutnya menggunakan teknik seleksi fitur non-linear untuk melihat apakah variabel demografi memiliki pola hubungan non-linear tersembunyi sebelum proses eliminasi variabel.
2. Diharapkan pada pengembangan selanjutnya menerapkan teknik manipulasi data, seperti SMOTE (*Synthetic Minority Over-sampling Technique*) atau melakukan pengumpulan data tambahan agar tidak terjadi dominasi pada salah satu kategori saja sehingga performa prediksi model menjadi lebih aktif dan seimbang.

Daftar Pustaka

- Greninger, D. W., Hampton, V. L., Kitt, K. A., & Achacoso, J. A. 1996. Ratios and Benchmarks for Measuring the Financial Well-Being of Families and Individuals. *Financial Services Review*, 5(1): 57–70.
- Hadley Wickham. 2014. Tidy Data. *Journal of Statistical Software*, 59(10): 1–23.
- Hamid, F.S., Loke, Y.J., & Chin, P.N. 2023. Determinants of Financial Resilience: Insights from An Emerging Economy. *Journal of Social and Economic Development*, 25:479-499.
- Han, J., Kamber, M., & Pei, J. 2012. *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- Hastie, T., Tibshirani, R., & Friedman, J. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. 2021. *An Introduction to Statistical Learning with Applications in R* (2nd ed.). Springer.
- Kempson, E., Finney, A., & Poppe, C. 2017. *Financial Well-Being: A Conceptual Model and Preliminary Analysis*. SIFO Project Note.
- Lusardi, A., Hasler, A., & Yakoboski, P.J. 2020. Building Up Financial Literacy and Financial Resilience. *Mind & Society*, 20: 181-187.
- McKnight, A., & Rucci, M. 2020. *The Financial Resilience of Households: 22 Country Study with New Estimates, Breakdowns by Household Characteristics and a Review of Policy Options*. European Commission.
- Mukaka, M. M. 2012. A Guide to Appropriate Use of Correlation Coefficient in Medical Research. *Malawi Medical Journal*, 24(3): 69–71.
- Otoritas Jasa Keuangan. 2025. *Strategi Nasional Literasi Keuangan Indonesia (SNLKI) 2021-2025*. OJK.
- Ratner, A., Hancock, B. T., Dunnmon, J., Sala, F., Pandey, S., & Ré, C. 2020. Snorkel: Rapid Training Data Creation with Weak Supervision. *The VLDB Journal*, 29(2–3): 709–730.
- Tukey, J. W. 1977. *Exploratory Data Analysis*. Addison-Wesley.